林锐, 高军礼. 基于双时序动态捕捉与分组坐标注意力的视触觉滑动检测[J]. 广东工业大学学报. doi: 10.12052/gdutxb.260049.
Lin Rui, Gao Junli. Vision-tactile slip detection based on bi-temporal dynamic capture and grouped coordinate attention[J]. Journal of Guangdong University of Technology. doi: 10.12052/gdutxb.260049.

基于双时序动态捕捉与分组坐标注意力的视触觉滑动检测

林　锐，高军礼
（广东工业大学　自动化学院, 广东　广州 510006）

摘要: 针对当前机器人抓取滑动检测方法在滑动特征捕捉、冗余噪声抑制方面存在不足，导致检测精度不高、模型泛化能力受限的问题，本文提出一种基于双时序动态捕捉与分组坐标注意力的视触觉滑动检测方法，并构建了视觉与触觉并行的特征提取链路和视触觉、跨模态特征的自适应融合架构。根据滑动事件的时序特征，本文设计了双时滑动感知融合模块，以增强网络对滑动发生瞬间的提取能力。为提升网络抑制冗余信息干扰的能力，本文设计了全局分组坐标注意力模块，对视触觉、跨模态特征进行自适应动态权重分配，以挖掘跨模态间的互补特性。实验结果表明，本文所提方法相比已有方法最多提升了16.1个百分点。在实体机器人实验中，对于16种未见物体，滑动检测的准确率为98.43%，由此验证了该方法在实际抓取过程中的有效性和应用潜力。

关键词: 滑动检测；视触觉融合；注意力机制；跨模态交互；机器人抓取
中图分类号: TP242　　**文献标志码:** A　　**文章编号:** 1007–7162(2026)00–0001–13

Vision-tactile Slip Detection Based on Bi-temporal Dynamic Capture and Grouped Coordinate Attention

Lin Rui, Gao Junli
(School of Automation, Guangdong University of Technology, Guangzhou 510006, Guangdong, China)

Abstract: To address the limitations of existing robotic grasping slip detection methods in capturing slip features and suppressing redundant noise, which lead to low detection accuracy and limited generalization ability, this paper proposes a vision-tactile slip detection method based on bi-temporal dynamic capture and grouped coordinate attention. A parallel feature extraction pipeline for vision and tactile modalities is constructed, along with an adaptive fusion architecture for vision-tactile and cross-modal features. According to the temporal characteristics of slip events, a Bi-temporal slip perception fusion module is designed to enhance the network's ability to extract features precisely at the moment of slip onset. To improve the network's capability in suppressing interference from redundant information, a Global grouped coordinate attention module is developed. Adaptive dynamic weight assignment is applied to vision-tactile and cross-modal features to fully exploit the complementary nature of different modalities. Experimental results demonstrate that the proposed method outperforms existing methods by margins of 16.1 percentage points, respectively. In physical robot experiments, the proposed method achieves a slip detection accuracy of 98.43% for 16 unseen objects, validating its effectiveness and application potential in practical robotic grasping tasks.

Key words: slip detection; vision-tactile fusion; attention mechanism; cross-modal interaction; robotic grasping

在机器人灵巧抓取、精密装配等典型操作任务中，视触觉多模态感知是机器人在非结构化复杂环境下实现稳定自主交互的重要基础[1]。在面对重量、材质刚度以及表面摩擦特性未知的目标物体时，机

收稿日期： 2026-04-14　**录用日期：** 2026-07-14　**网络首发日期：** 2026-08-26
基金项目： 国家自然科学基金资助面上项目(62573137)
作者简介： 林锐(2002–)，男，硕士研究生，主要研究方向为机器人抓取滑动检测，E-mail：1980445693@qq.com
通信作者： 高军礼(1973–)，男，副教授，博士，主要研究方向为机器人感知与人机交互，E-mail：13826067859@163.com

械臂容易因初始夹持力估计不足或外部物理扰动，出现物体滑动甚至脱落[2-3]。因此，准确识别抓取过程中的滑动状态，并为后续抓取力调节提供可靠反馈，是保障机械臂安全稳定操作的关键前提[4]。

面向机器人抓取滑动检测任务，现有基于单一视觉或单一触觉的感知方法，存在无法规避的固有物理局限性。纯视觉感知可提供宏观几何与空间位姿信息，但易受夹爪遮挡与光照突变干扰，导致滑动检测失效[5-6]；纯触觉感知对微观剪切力与局部纹理敏感，但缺乏全局视觉参考时，易将接触初期的稳态挤压形变误判为滑动，引发误报[7-9]。为解决单一模态的固有局限，研究人员已将视触觉多模态融合方法引入滑动检测任务的相关研究中。例如，Li等[10]率先探索了基于特征直接拼接的多模态融合框架并提出卷积神经网络–长短期记忆网络(Convolutional Neural Network-Long Short Term Memory，CNN-LSTM)模型，通过结合卷积神经网络与长短期记忆网络联合处理视触觉时间序列，有效提升了滑动检测的综合准确率。针对LSTM存在的序列计算效率低与遗忘问题，Yan等[11]提出了卷积神经网络–时序卷积网络(Convolutional Neural Network-Temporal Convolutional Network，CNN-TCN)，提升了视觉与触觉高频特征的融合效率。然而，现有视触融合方法仍存在明显不足：一是多数方法采用简单特征拼接方式，缺乏对不同模态特征贡献的自适应评估，导致模型在遮挡、噪声或模态信息不一致时鲁棒性受限；二是现有时序建模方法更侧重整体序列特征提取，对滑动发生瞬间相邻帧之间的微弱动态变化捕捉不足；三是常规全局池化或注意力建模过程容易削弱关键空间位置信息，影响模型对滑移方向和局部接触变化的判别能力。

针对上述问题，本文提出了一种基于双时序动态捕捉与分组坐标注意力的视触觉滑动检测网络。该网络引入针对滑动事件特点设计的双时滑动感知融合模块(Bi-temporal Slip Perception Fusion Module，BFM)，通过对多模态序列进行相邻帧的动态差分建模，精准捕获滑动发生瞬间的微观位移与高频纹理突变；设计全局分组坐标注意力模块(Global Grouped Coordinate Attention，GGCA)，在增强与滑动方向相关的特征权重的同时，跨通道滤除静态背景与稳态接触噪声。综合考量特征空间维度，本文探索并确立了较优的输入多模态序列长度，以实现感知精度与计算效率的最佳平衡。

综上所述，本文的主要贡献如下：

(1) 面向机器人抓取过程中的滑动检测任务，构建了一种视触觉特征融合网络架构。该架构通过视觉分支与触觉分支分别提取物体外观语义信息和接触动态信息，并进一步实现跨模态特征融合，从而增强模型对微小滑移变化的感知能力和复杂抓取场景下的抗干扰能力。

(2) 针对滑动发生瞬间相邻时刻动态变化不明显、视触觉特征中冗余信息易干扰滑移特征表达的问题，本文设计了双时滑动感知融合模块和全局分组坐标注意力模块。其中，BFM模块通过对相邻帧时序特征差异进行建模，增强网络对滑动瞬态变化的捕捉能力；GGCA模块在坐标注意力机制基础上引入分组策略，以抑制冗余特征干扰并保留关键空间信息，从而提升模型的检测准确率和鲁棒性。

(3) 在文献[10]和文献[12]提出的两个多模态数据集(以下简称GelSight数据集和Huang数据集)上展开了对比实验和消融实验，验证了本文所提模块对滑动检测性能的提升作用。在真实机械臂抓取实验平台上，对未见物体开展共320次抓取、抬升与运动测试，滑动检测准确率达98.43%，进一步验证了本文方法的有效性和实际应用价值。

1 相关工作

1.1 基于视触融合的滑动检测

伴随多模态感知技术的快速发展，基于视触觉融合的机器人抓取滑动检测方法已成为该领域的研究热点[13-15]。相较于基于纯视觉[16-18]或纯触觉[19-21]单模态滑动检测方法，视触觉融合策略能够融合视觉全局语义与触觉局部动态受力信息，深度挖掘并利用模态间的天然互补优势，更符合机器人抓取滑动检测的需求。Hu等[9]基于GelSight Mini触觉传感器提出实时滑动检测方法，通过接触力场及熵特征表征滑动过程中的局部接触变化，验证了触觉动态信息对滑动检测的重要性，但该方法对视觉语义信息利用不足。Li等[10]率先探索了将外部视觉图像序列与触觉数据深度结合的多模态滑动检测框架，采用卷积神经网络CNN并联合长短期记忆网络LSTM对视触觉特征序列进行时空演变建模，验证了多模态融合的滑动分类准确率显著超越传统的单模态方法。为了进一步挖掘长程时间依赖，黄兆基等[12]提出利用多尺度时序卷积网络(Multi-Scale Temporal Convolutional Network，MS-TCN)来提取视触觉数据的连续时序特征，有效提升了复杂物体的滑动检测率。此外，Zhang等[22]通过强化学习对跨模态特征进

行联合表征。Tang等[23]提出视觉–触觉多模态特征融合网络(Visual-Tactile Multi-modal Feature Fusion Network，VTMF^{2}N)，通过通道洗牌与交叉注意力模块促进视觉和触觉信息交互，验证了深层跨模态特征融合对滑动检测的有效性。Taunyazov等[16]构建了事件驱动的视觉–触觉感知系统，将NeuTouch触觉传感器与事件相机结合，并利用视觉–触觉脉冲神经网络实现旋转滑动检测，体现了多模态动态感知的应用潜力。

除直接面向滑动检测的研究外，近年来视触觉融合也被广泛应用于抓取状态检测和稳定抓取任务中。Ruan等[24]提出一种名为RFCT的新型视触觉融合模型，面向弱刚度目标抓取状态检测构建视觉–触觉融合框架，并结合增量维度张量积融合与注意力机制(Convolutional Block Attention Module，CBAM)增强关键多模态特征。Yang等[25]提出YGC(YOLOv5s-GRCNN-CNN)模型，将视觉–触觉融合应用于弱刚度目标稳定抓取任务，通过目标检测、姿态生成和抓取状态检测等环节提升复杂目标的抓取稳定性。上述研究表明，视觉–触觉融合能够有效增强机器人抓取状态感知能力，但针对滑动瞬间短时动态差异的建模仍有进一步提升空间。

然而，现有视触觉融合方法在滑动检测任务中仍存在一定局限。一方面，部分方法主要依赖特征拼接或序列建模实现模态融合，对滑动发生瞬间相邻时刻之间的细微动态变化关注不足；另一方面，传统LSTM等时序建模结构在处理较长序列时容易出现有效特征衰减，难以持续捕捉关键滑移变化。由于滑动往往表现为接触状态在短时间内的突变，若缺乏对相邻帧间动态差异的显式建模，模型容易受到稳态接触信息或背景冗余特征的干扰。

为进一步提升视触觉序列中全局依赖与跨模态关联的建模效果，研究人员将基于自注意力机制的Transformer架构引入多模态融合与视频时序理解任务，展现出优异的时空关联建模能力[26]。Bertasius等[27]首次将Transformer引入视频动作识别，通过分离空间与时间注意力成功捕捉了长距离的全局依赖关系。Han等[28]率先探索了时空Transformer在视触觉多模态抓取中的应用，证实了其在捕捉长程图像序列依赖上优于传统的CNN-LSTM架构。然而，标准Transformer结构在滑动检测任务中仍存在一定不足。其全局自注意力机制虽然有利于建模长程依赖，但也可能将无关视觉静态背景和触觉冗余形变特征赋予较高权重，不仅引入较大的计算开销[29]，还可能削弱有效微观滑移信号的表达。此外，针对滑动事件的瞬态变化特点，标准自注意力机制缺乏对相邻帧相对变化的显式差分建模能力[30]。

1.2　注意力机制在滑动检测中的作用

注意力机制能够根据任务需求自适应分配特征权重，突出关键响应并抑制冗余信息干扰[31]，已广泛应用于图像识别、语义分割和多模态感知等任务。Hu等[32]提出挤压–激励网络(Squeeze and Excitation Networks，SENet)，通过建模通道间依赖关系自适应重标定通道特征响应，提升了网络对关键通道信息的表达能力。Woo等[33]进一步提出卷积块注意力模块(Convolutional Block Attention Module，CBAM)，将通道注意力与空间注意力串联，在增强有效特征的同时抑制背景噪声。Fu等[34]设计双重注意力网络，从空间位置和通道维度捕获全局上下文依赖，提高了复杂场景下的特征表征能力。Hou等[35]提出坐标注意力机制，在通道注意力中嵌入方向位置信息，使网络在捕获长程依赖的同时保留关键空间坐标信息。上述研究表明，通道注意力能够突出关键特征响应，空间注意力能够定位显著区域，二者协同有助于增强网络对有效信息的表达能力，并抑制无关背景干扰。对于视触觉滑动检测任务，注意力机制不仅能够增强关键特征，还可抑制冗余信息和噪声干扰。视觉模态中存在与滑动无关的背景信息，触觉模态中包含稳态挤压或接触噪声等冗余响应，若对所有特征同等建模，容易削弱关键滑移特征的表达。

综上，现有方法已证明视触觉融合、Transformer和注意力机制在滑动检测中的有效性，但在滑动瞬态变化捕捉、冗余噪声抑制和关键空间特征保持方面仍有提升空间。为此，本文设计双时滑动感知融合模块和全局分组坐标注意力模块，前者用于增强相邻时刻动态差异建模，提升对滑动瞬间变化的感知能力；后者用于抑制冗余特征干扰并保留关键空间信息，从而进一步提高视触觉滑动检测的准确性与鲁棒性。

2　基于视触融合的滑动检测网络

2.1　网络整体架构

本文所提出的基于双时序动态捕捉与分组坐标注意力的视触融合滑动检测网络模型如图1所示。针对视觉与触觉模态互补的特点，采用双分支结构，输入为视觉和触觉帧序列 $\boldsymbol{X}_{\mathrm{V}} \in \mathbb{R}^{B\times T\times 3\times H\times W}$ 和 $\boldsymbol{X}_{\mathrm{T}} \in \mathbb{R}^{B\times T\times 3\times H\times W}$。在浅层特征嵌入阶段，视觉分支与

触觉分支根据模态的差异采用差异化的前端嵌入策略。为增强网络对滑动瞬间微弱动态变化的捕捉能力，设计双时滑动感知融合模块(BFM)；同时，引入全局分组坐标注意力模块(GGCA)，在保留关键空间位置信息的同时，抑制背景冗余和稳态接触噪声对滑动判别的干扰。经过BFM与GGCA模块的精细化特征挖掘后，网络进入深层特征交互阶段，视触觉单模态分支首先通过通道自注意力机制对特征通道间的依赖关系进行建模。随后，在单模态及跨模态路径中堆叠了因子化点积Transformer编码器，用于建模序列中的时空依赖关系，并促进视觉宏观语义信息与触觉局部动态信息的交互融合。最后，各分支经全局平均池化生成的四组特征向量$\boldsymbol{F}_{\mathrm{V}}^{\mathrm{uni}}$、$\boldsymbol{F}_{\mathrm{V}}^{\mathrm{cross}}$、$\boldsymbol{F}_{\mathrm{T}}^{\mathrm{cross}}$、$\boldsymbol{F}_{\mathrm{T}}^{\mathrm{uni}}$进行动态加权融合，由多层感知机MLP分类头输出最终的滑动判定结果。

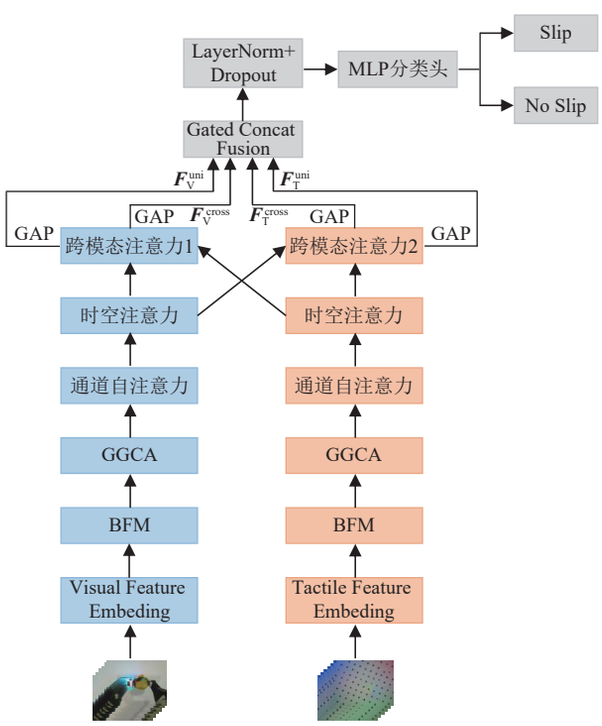


图 1 视触融合滑动检测网络

Fig.1 Vision-tactile fusion slip detection network

2.2 视触觉数据差异化前端嵌入方式

视觉图像与触觉图像在成像机理与信息分布上存在显著差异。视觉数据包含物体颜色、空间位置和全局语义信息，而触觉数据更关注接触区域的局部纹理。若两类模态采用相同的前端嵌入方式，容易削弱各自的特征表达优势。因此，本文设计了差异化前端嵌入策略。

对于视觉输入序列$\boldsymbol{X}_{\mathrm{V}} \in \mathbb{R}^{B\times T\times 3\times H\times W}$，其主要作用是提供物体外观和全局空间位置信息。其中，B表示训练与推理时的批次大小，T表示输入的连续时间步长，H和W表示图像的空间高度和宽度。因此，视觉分支采用标准的视觉Transformer均匀分块嵌入策略，如图2所示。给定图块尺寸为$P_H \times P_W$，图像被划分为$N = \dfrac{H}{P_H} \times \dfrac{W}{P_W}$个非重叠图像块，并通过卷积核大小和步长均为$(P_H, P_W)$的二维卷积层，将图像块映射到$D$维特征空间。为保留图像块之间的空间位置信息，引入可学习的绝对位置编码$\boldsymbol{E}_{\mathrm{pos}}$，其计算过程如下

$$\boldsymbol{z}_{\mathrm{v}}^{0} = \mathrm{Conv}_{P_H\times P_W}(\boldsymbol{X}_{\mathrm{V}}) + \boldsymbol{E}_{\mathrm{pos}} \tag{1}$$

式中，$\boldsymbol{z}_{\mathrm{v}}^{0}$表示视觉分支经前端嵌入后的输入特征；$\boldsymbol{X}_{\mathrm{V}}$表示输入的视觉特征；$\boldsymbol{E}_{\mathrm{pos}}$表示可学习的位置编码。

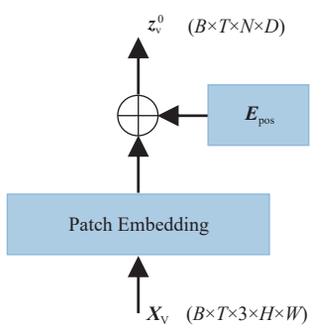


图 2 视觉分支前端嵌入结构

Fig.2 Front-end embedding structure of the visual branch

对于触觉输入序列$\boldsymbol{X}_{\mathrm{T}} \in \mathbb{R}^{B\times T\times 3\times H\times W}$，由于触觉图像中的纹理变化和接触形变通常集中在局部区域，若直接采用大步长分块，容易破坏连续纹理结构。因此，触觉分支采用轻量化卷积前端，以逐步提取局部纹理和接触形变特征，如图3所示。该方式通过3×3卷积完成局部特征提取和空间降采样。同时，考虑到触觉滑移特征对局部位置变化较为敏感，采用零填充的3×3深度卷积实现隐式位置编码，以在保留局部空间关系的同时增强触觉特征表达。其计算过程如下

$$\tilde{\boldsymbol{X}}_{\mathrm{T}} = \mathcal{F}_{\mathrm{stem}}(\boldsymbol{X}_{\mathrm{T}}) \tag{2}$$

$$\hat{\boldsymbol{X}}_{\mathrm{T}} = \tilde{\boldsymbol{X}}_{\mathrm{T}} + \mathrm{DWConv}(\tilde{\boldsymbol{X}}_{\mathrm{T}}) \tag{3}$$

$$\boldsymbol{z}_{\mathrm{t}}^{0} = \mathrm{Proj}(\hat{\boldsymbol{X}}_{\mathrm{T}}) \tag{4}$$

式中，$\mathcal{F}_{\mathrm{stem}}(\cdot)$表示轻量化触觉特征提取前端；$\tilde{\boldsymbol{X}}_{\mathrm{T}}$表示经过局部特征提取和空间降采样后的中间特征图；DWConv(·)表示采用零填充的3×3深度卷积进行隐式位置编码；$\hat{\boldsymbol{X}}_{\mathrm{T}}$表示经残差连接增强后的触觉特征；Proj(·)为投影层，用于将触觉特征图转换为输入后续网络的初始Token序列$\boldsymbol{z}_{\mathrm{t}}^{0}$。

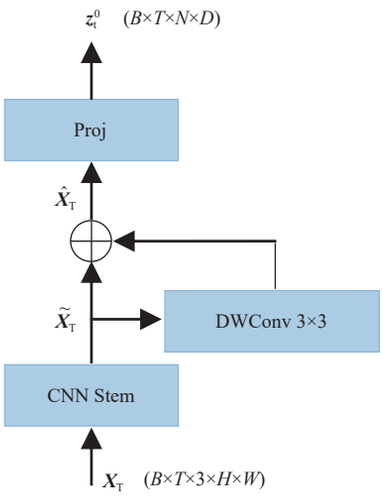


图 3　触觉分支前端嵌入结构

Fig.3　Front-end embedding structure of the tactile branch

2.3　滑动特征增强模块

2.3.1　双时滑动感知融合模块

在机器人抓取与操作任务中，滑动本质上是一个短时、动态变化过程。无论是视觉图像中的微小位移，还是触觉图像中的局部纹理形变，均表现为相邻时刻之间的细微特征差异。因此，仅依赖单帧特征或常规时序建模，容易忽略滑动发生瞬间的弱动态变化。为增强网络对连续时间微小变化的感知能力，本文设计了双时滑动感知融合模块(BFM)，其具体网络结构如图4所示，图中Cat表示特征拼接操作。该模块以相邻两帧的特征($\boldsymbol{T}_1$和$\boldsymbol{T}_2$)作为输入。考虑到滑动特征在空间尺度上具有差异性，模块首先采用3×3、5×5和7×7三种尺度的二维卷积分别提取不同感受野下的局部动态特征，得到多尺度增强特征$\boldsymbol{M}_1$和$\boldsymbol{M}_2$。其计算过程为

$$\boldsymbol{M}_k=\sum_{K\in\{3,5,7\}}\mathrm{ReLU}(\mathrm{Conv}_{K\times K}(\boldsymbol{T}_k)),k\in\{1,2\} \tag{5}$$

式中，$\boldsymbol{M}_k$表示第k个时刻的多尺度增强特征；$\boldsymbol{T}_k$表示第k时刻的时序特征；$\mathrm{Conv}_{K\times K}(\cdot)$表示卷积尺寸为$K\times K$的二维卷积操作；ReLU表示线性单元激活函数。

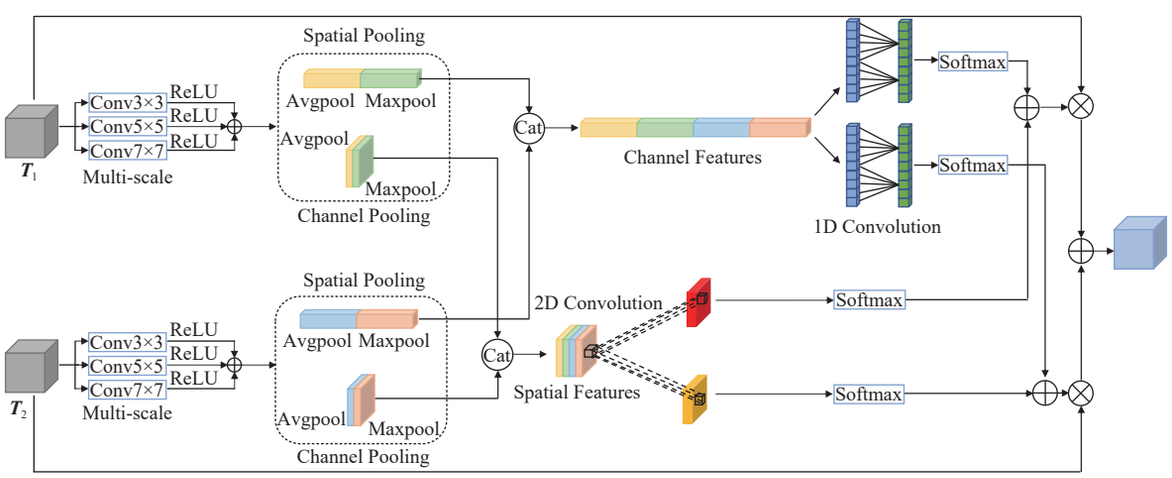


图 4　双时滑动感知融合模块结构

Fig.4　Structure of the bi-temporal slip perception fusion module

随后，BFM模块从空间与通道两个维度构建时序融合注意力机制，用于自适应评估相邻两帧特征对滑动判别的贡献。在通道注意力分支中，分别对$\boldsymbol{M}_1$和$\boldsymbol{M}_2$进行平均池化和最大池化，以聚合全局上下文信息；再通过一维卷积和Softmax函数生成通道注意力权重$\boldsymbol{W}_{\mathrm{c}}^{(1)}$和$\boldsymbol{W}_{\mathrm{c}}^{(2)}$。其计算过程为

$$\begin{aligned}\boldsymbol{W}_{\mathrm{c}}^{(k)}=&(\mathrm{Softmax}(\mathrm{Conv1D}([P_{\mathrm{avg}}(\boldsymbol{M}_1);P_{\mathrm{max}}(\boldsymbol{M}_1);\\&P_{\mathrm{avg}}(\boldsymbol{M}_2);P_{\mathrm{max}}(\boldsymbol{M}_2)])))^{(k)},k\in\{1,2\}\end{aligned} \tag{6}$$

式中，$\boldsymbol{W}_{\mathrm{c}}^{(k)}$表示分配给第$k$帧时序特征的通道注意力权重向量；$P_{\mathrm{avg}}$表示全局平均池化；$P_{\mathrm{max}}$表示全局最大池化；$[\cdot;\cdot]$表示沿通道特征拼接操作；Conv1D表示一维卷积操作；Softmax$(\cdot)$表示归一化指数激活函数。

在空间注意力分支中，为突出滑动发生的关键局部区域，分别对$\boldsymbol{M}_1$和$\boldsymbol{M}_2$进行空间维度上的平均池化与最大池化，并通过7×7二维卷积生成空间注意力权重$\boldsymbol{W}_{\mathrm{s}}^{(1)}$和$\boldsymbol{W}_{\mathrm{s}}^{(2)}$。其计算过程为

$$\begin{aligned}\boldsymbol{W}_{\mathrm{s}}^{(k)}=&(\mathrm{Softmax}(\mathrm{Conv2D}_{7\times7}([P_{\mathrm{avg}}(\boldsymbol{M}_1);P_{\mathrm{max}}(\boldsymbol{M}_1);\\&P_{\mathrm{avg}}(\boldsymbol{M}_2);P_{\mathrm{max}}(\boldsymbol{M}_2)])))^{(k)},k\in\{1,2\}\end{aligned} \tag{7}$$

式中，$\boldsymbol{W}_{\mathrm{s}}^{(k)}$表示分配给第$k$帧时序特征的空间注意力权重向量。

在获得通道与空间维度的时序注意力权重后，将二者相加得到第k帧的联合注意力权重$\boldsymbol{W}^{(k)}$。最

后，根据注意力权重对相邻两帧特征进行动态融合，得到增强后的时空特征$\boldsymbol{T}_{\text{out}}$。其计算过程为

$$\boldsymbol{W}^{(k)}=\boldsymbol{W}_{\text{c}}^{(k)}+\boldsymbol{W}_{\text{s}}^{(k)},k\in\{1,2\} \tag{8}$$

$$\boldsymbol{T}_{\text{out}}=\boldsymbol{W}^{(1)}\otimes\boldsymbol{T}_1+\boldsymbol{W}^{(2)}\otimes\boldsymbol{T}_2 \tag{9}$$

通过上述过程，BFM模块能够在多尺度空间特征提取的基础上，自适应强化相邻帧之间与滑动相关的动态差异，同时抑制稳态接触和背景冗余信息对滑动判别的干扰。

2.3.2 全局分组坐标注意力模块

在利用BFM模块提取到相邻帧的动态时序线索后，网络还需精准定位滑动发生的核心空间区域。传统通道注意力机制通常通过全局池化压缩空间信息，虽然能够突出重要通道，但容易丢失滑移方向和局部接触位置等关键空间线索。为此，本文设计全局分组坐标注意力模块(GGCA)，其结构如图5所示。图中C为特征图的通道数。该模块通过通道分组降低冗余特征干扰，并结合高度和宽度两个方向的坐标注意力，增强网络对局部位移和纹理变化的表征能力。

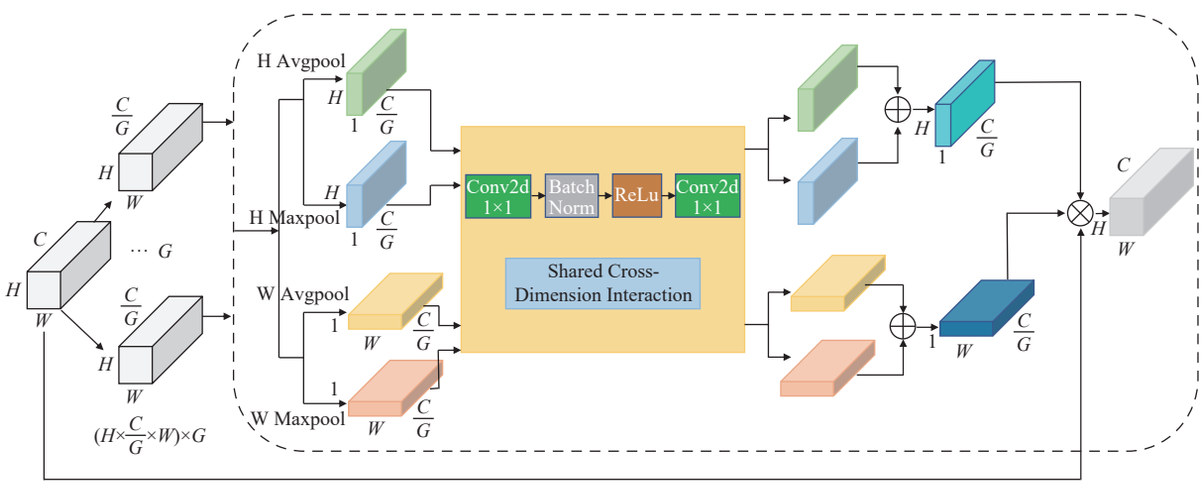


图5 全局分组坐标注意力模块结构

Fig.5 Structure of the global grouped coordinate attention module

首先，将输入特征$\boldsymbol{X}\in\mathbb{R}^{B\times C\times H\times W}$沿通道维度均匀划分为$G$个子组(本文设定$G=4$)，记为$\boldsymbol{X}=[\boldsymbol{X}_1,\boldsymbol{X}_2,\cdots,\boldsymbol{X}_G]$，其中各子特征组$\boldsymbol{X}_g\in\mathbb{R}^{B\times\frac{C}{G}\times H\times W}$。针对每一个子组，分别在高度方向和宽度方向进行一维平均池化与最大池化，以同时保留全局统计信息和显著局部响应。对于第c个通道，其计算过程为

$$z_{h,\text{avg}}^{c}(h)=\frac{1}{W}\sum_{0\leqslant j<W}x_c(h,j) \tag{10}$$

$$z_{h,\max}^{c}(h)=\max_{0\leqslant j<W}x_c(h,j) \tag{11}$$

$$z_{w,\text{avg}}^{c}(w)=\frac{1}{H}\sum_{0\leqslant i<H}x_c(i,w) \tag{12}$$

$$z_{w,\max}^{c}(w)=\max_{0\leqslant i<H}x_c(i,w) \tag{13}$$

式中，$x_c(h,j)$和$x_c(i,w)$分别表示输入特征子组的第c个通道在对应空间位置处的特征响应；H和W分别为该特征图的空间高度和宽度；$z_{h,\text{avg}}^{c}(h)$和$z_{h,\max}^{c}(h)$分别表示第c个通道沿宽度方向在高度h处进行一维全局平均池化与最大池化后提取的特征；同理，$z_{w,\text{avg}}^{c}(w)$和$z_{w,\max}^{c}(w)$分别表示该通道沿高度方向在宽度w处进行相应池化操作后提取的特征。

获取四组方向感知特征后，为实现跨通道的信息交互，模块引入了一个共享的跨维交互网络(Shared Cross-Dimension Interaction)。该交互网络由一个降维的1×1卷积、批量归一化、ReLU激活函数以及一个升维的1×1卷积组成。通过共享参数设计，模块能够减少额外计算开销，并增强不同方向坐标特征之间的信息交互。随后，利用Sigmoid函数生成高度方向和宽度方向的注意力权重。其计算过程为

$$\boldsymbol{\alpha}_h=\sigma(\mathcal{F}_{\text{shared}}(\boldsymbol{z}_{h,\text{avg}})+\mathcal{F}_{\text{shared}}(\boldsymbol{z}_{h,\max})) \tag{14}$$

$$\boldsymbol{\alpha}_w=\sigma(\mathcal{F}_{\text{shared}}(\boldsymbol{z}_{w,\text{avg}})+\mathcal{F}_{\text{shared}}(\boldsymbol{z}_{w,\max})) \tag{15}$$

式中，$\boldsymbol{\alpha}_h$与$\boldsymbol{\alpha}_w$分别表示生成的沿高度和宽度方向的坐标注意力权重矩阵；$\sigma(\cdot)$表示Sigmoid激活函数；$\mathcal{F}_{\text{shared}}(\cdot)$表示共享的跨维交互网络。

最后，将两个方向的注意力权重与原始子组特征$\boldsymbol{X}_g$进行逐元素相乘，完成空间位置信息的动态嵌入。各子组处理完成后，在通道维度上进行拼接，形

成最终的输出特征$\boldsymbol{Y}$。其计算过程为

$$\boldsymbol{Y}=\mathrm{Cat}_{g=1}^{G}(\boldsymbol{X}_g\otimes\boldsymbol{\alpha}_{h,g}\otimes\boldsymbol{\alpha}_{w,g}) \tag{16}$$

式中，g表示特征子组索引；$\boldsymbol{Y}$表示GGCA模块最终输出的增强特征；$\boldsymbol{X}_g$表示沿通道维度均匀划分后的第g个子特征组；$\boldsymbol{\alpha}_{h,g}$与$\boldsymbol{\alpha}_{w,g}$分别表示第$g$个子特征组在高度和宽度方向上计算得到的一维坐标注意力权重向量。

通过上述过程，GGCA模块能够在保留滑动相关空间坐标信息的同时，抑制冗余通道和背景噪声干扰，从而提升网络对滑动区域和滑移方向的判别能力。

2.4　单模态多维自注意力编码

经过滑动特征增强模块的初期处理，网络在浅层阶段已有效捕获了局部的微小滑动形变与关键空间坐标先验。为了进一步挖掘单一模态内部的通道依赖和时空关联关系，本文在视觉与触觉双流分支引入单模态多维自注意力编码。该编码由通道自注意力与时空注意力组成，用于从通道、空间和时间三个维度增强单模态特征表达。

首先，将单模态特征$\boldsymbol{X}\in\mathbb{R}^{N\times C}$(其中$N$为时空序列长度，$C$为通道维度)输入通道自注意力模块。与传统时序维度上的注意力计算不同，通道自注意力在特征维度上计算相关性。具体地，先对输入特征进行线性映射，得到查询矩阵$\boldsymbol{Q}_{\mathrm{c}}$、键矩阵$\boldsymbol{K}_{\mathrm{c}}$和值矩阵$\boldsymbol{V}_{\mathrm{c}}$，再计算通道间相似度，得到通道注意力权重矩阵$\boldsymbol{A}_{\mathrm{c}}$。随后，将该权重矩阵作用于值矩阵$\boldsymbol{V}_{\mathrm{c}}$，并通过残差连接得到通道增强后的输出特征$\widehat{\boldsymbol{X}}$。其计算过程为

$$\boldsymbol{A}_{\mathrm{c}}=\mathrm{Softmax}\left(\frac{\boldsymbol{Q}_{\mathrm{c}}\boldsymbol{K}_{\mathrm{c}}^{\mathrm{T}}}{\sqrt{d_{\mathrm{c}}}}\right) \tag{17}$$

$$\widehat{\boldsymbol{X}}=\boldsymbol{X}+\mathrm{Proj}((\boldsymbol{A}_{\mathrm{c}}\boldsymbol{V}_{\mathrm{c}})^{\mathrm{T}}) \tag{18}$$

式中，d_{c}是防止内积结果过大的缩放因子；Proj(·)表示特征维度的线性映射。

通过上述过程，网络能够自适应建模不同通道之间的依赖关系，突出与滑动状态相关的关键通道响应。

随后，将通道增强后的特征$\widehat{\boldsymbol{X}}$输入时空注意力模块。考虑到机器人连续抓取过程中存在明显的时序关联，若直接计算三维全局时空注意力，将带来较高计算开销。因此，本文采用因子化时空注意力机制，将注意力计算分解为空间与时间分支。空间分支用于建模单帧内部不同图块之间的空间依赖关系，时间分支用于捕捉相同空间位置在不同帧之间的动态变化。其计算过程为

$$\boldsymbol{Y}_{\mathrm{s}}=\mathrm{Softmax}\left(\frac{\boldsymbol{Q}_{\mathrm{s}}\boldsymbol{K}_{\mathrm{s}}^{\mathrm{T}}}{\sqrt{d_{\mathrm{k}}}}\right)\boldsymbol{V}_{\mathrm{s}} \tag{19}$$

$$\boldsymbol{Y}_{\mathrm{t}}=\mathrm{Softmax}\left(\frac{\boldsymbol{Q}_{\mathrm{t}}\boldsymbol{K}_{\mathrm{t}}^{\mathrm{T}}}{\sqrt{d_{\mathrm{k}}}}\right)\boldsymbol{V}_{\mathrm{t}} \tag{20}$$

$$\boldsymbol{Y}=\widehat{\boldsymbol{X}}+\mathrm{Linear}(\mathrm{Concat}(\boldsymbol{Y}_{\mathrm{s}},\boldsymbol{Y}_{\mathrm{t}})) \tag{21}$$

式中，$\boldsymbol{Y}_{\mathrm{s}}$和$\boldsymbol{Y}_{\mathrm{t}}$分别为解耦后的空间特征和时间特征；$\boldsymbol{V}_{\mathrm{s}}$和$\boldsymbol{V}_{\mathrm{t}}$分别为空间与时间分支的投影矩阵；Concat(·)表示沿特征维度进行的拼接操作；Linear(·)是线性映射。

2.5　跨模态交互与自适应门控融合机制

完成单模态深层编码后，视觉与触觉分支已分别提炼出丰富的时空语义表征。然而，滑动检测依赖视觉与触觉信息的协同判断，仅对两类模态分别建模难以充分利用其互补关系。因此，本文引入跨模态交互模块和自适应门控融合机制，以实现视觉全局语义信息与触觉局部动态信息的有效融合。

首先，将单模态编码后的视觉特征$\boldsymbol{Y}_{\mathrm{V}}$与触觉特征$\boldsymbol{Y}_{\mathrm{T}}$输入跨模态注意力模块。该模块包括视觉引导触觉和触觉引导视觉两个分支。在视觉引导触觉分支中，以触觉特征作为查询，以视觉特征作为键和值，使触觉特征能够感知视觉模态中的物体位姿和全局空间信息；在触觉引导视觉分支中，以视觉特征作为查询，以触觉特征作为键和值，使视觉特征能够融合触觉模态中的局部接触和滑移线索。其计算过程为

$$\boldsymbol{F}_{\mathrm{T}}^{\mathrm{cross}}=\mathrm{Softmax}\left(\frac{\boldsymbol{Q}_{\mathrm{T}}\boldsymbol{K}_{\mathrm{V}}^{\mathrm{T}}}{\sqrt{d_{\mathrm{k}}}}\right)\boldsymbol{V}_{\mathrm{V}} \tag{22}$$

$$\boldsymbol{F}_{\mathrm{V}}^{\mathrm{cross}}=\mathrm{Softmax}\left(\frac{\boldsymbol{Q}_{\mathrm{V}}\boldsymbol{K}_{\mathrm{T}}^{\mathrm{T}}}{\sqrt{d_{\mathrm{k}}}}\right)\boldsymbol{V}_{\mathrm{T}} \tag{23}$$

式中，$\boldsymbol{Q}_{\mathrm{T}}$，$\boldsymbol{K}_{\mathrm{T}}$，$\boldsymbol{V}_{\mathrm{T}}$分别为触觉特征$\boldsymbol{Y}_{\mathrm{T}}$经线性映射得到的查询、键、值矩阵；$\boldsymbol{Q}_{\mathrm{V}}$，$\boldsymbol{K}_{\mathrm{V}}$，$\boldsymbol{V}_{\mathrm{V}}$分别为视觉特征$\boldsymbol{Y}_{\mathrm{V}}$经线性映射得到的查询、键、值矩阵，$d_{\mathrm{k}}$为防止内积过大的缩放因子。

为了对单模态特征与跨模态特征进行有效融合，分别对单模态特征$\boldsymbol{F}_{\mathrm{V}}^{\mathrm{uni}}$，$\boldsymbol{F}_{\mathrm{T}}^{\mathrm{uni}}$与跨模态特征$\boldsymbol{F}_{\mathrm{V}}^{\mathrm{cross}}$，$\boldsymbol{F}_{\mathrm{T}}^{\mathrm{cross}}$进行全局平均池化，得到四组定长特征向量。考虑到在不同的抓取环境下视觉和触觉信息的可靠性不同，本文引入自适应门控机制，动态调节不同特征对最终判别结果的贡献。其计算过程为

$$\lambda=\sigma(\mathrm{MLP}([\boldsymbol{f}_{\mathrm{V}}^{\mathrm{uni}};\boldsymbol{f}_{\mathrm{V}}^{\mathrm{cross}};\boldsymbol{f}_{\mathrm{T}}^{\mathrm{cross}};\boldsymbol{f}_{\mathrm{T}}^{\mathrm{uni}}])) \tag{24}$$

$$\boldsymbol{f}_{\mathrm{fused}}=\lambda\otimes\mathrm{Concat}(\boldsymbol{f}_{\mathrm{V}}^{\mathrm{uni}},\boldsymbol{f}_{\mathrm{V}}^{\mathrm{cross}},\boldsymbol{f}_{\mathrm{T}}^{\mathrm{cross}},\boldsymbol{f}_{\mathrm{T}}^{\mathrm{uni}}) \tag{25}$$

式中，$\boldsymbol{f}_{\mathrm{V}}^{\mathrm{uni}}$、$\boldsymbol{f}_{\mathrm{T}}^{\mathrm{uni}}$、$\boldsymbol{f}_{\mathrm{V}}^{\mathrm{cross}}$、$\boldsymbol{f}_{\mathrm{T}}^{\mathrm{cross}}$为四组特征压缩后的定长特征向量；$\sigma(\cdot)$为Sigmoid激活函数；$\otimes$表示逐元素相乘；$\lambda$表示门控权重系数向量；MLP(·)表示多层感知机网络。门控系数能够根据当前输入特征的显著性，自适应地抑制冗余信息并激发关键滑动线索。

最后，融合后的全局特征向量$\boldsymbol{f}_{\mathrm{fused}}$经过由LayerNorm与Dropout组成的归一化层后，送入MLP分类头。分类头通过非线性映射输出最终滑动或非滑动的概率。

3 实验结果与分析

3.1 实验设置

3.1.1 数据集

在实验部分，为全面评估本文提出的视触觉融合滑动检测网络的有效性与泛化能力，采用GelSight数据集和Huang数据集进行网络的训练、测试以及模型泛化能力的验证。GelSight数据集是由安装在机械臂夹爪上的高分辨率光学触觉传感器(GelSight)与外部标准RGB相机同步采集生成，包含了104种具有不同材质、几何形状、重量以及表面纹理的日常物体，其中94种物体的数据用于构建训练集，剩余10种网络未曾见过的物体划分为测试集。Huang数据集是基于7自由度xArm机械臂、RealSense D455 RGB相机以及XELA触觉传感器采集而成，包含50个具有不同大小、形状、材料和重量的日常物体，其中40个物体作为训练集，剩余10个物体作为测试集。与GelSight数据集相比，虽然在物体数量上相对较少，但其物体选择更侧重于实际机器人抓取场景中的典型操作对象，覆盖了规则与不规则形状、光滑与粗糙表面、轻质与相对较重物体等多种情况，能够较好反映真实抓取过程中由物体外形、接触状态和表面摩擦差异引起的滑动变化。数据采集过程中，RGB图像用于表征物体外观、位姿及全局场景信息，XELA触觉传感器用于记录夹爪与物体接触过程中的局部触觉响应，从而形成具有时间连续性的视触觉多模态数据。该数据集为验证本文方法在不同触觉传感器、不同物体属性以及真实机械臂抓取条件下的适应性提供了实验基础。

3.1.2 评价指标

滑动检测本质上是一个多模态二分类任务，为了全面、客观地评估网络在测试集上的综合感知性能，本文遵循文献[7]的评估标准，采用混淆矩阵作为基础，并选取准确率(Accuracy)、精确率(Precision)、召回率(Recall)以及F1分数(F1-Score)四个主流分类指标对模型进行定量评价。其计算过程如式(26)~(29)所示。

$$A=\frac{N_{\mathrm{TP}}+N_{\mathrm{TN}}}{N_{\mathrm{TP}}+N_{\mathrm{TN}}+N_{\mathrm{FP}}+N_{\mathrm{FN}}} \tag{26}$$

$$P=\frac{N_{\mathrm{TP}}}{N_{\mathrm{TP}}+N_{\mathrm{FP}}} \tag{27}$$

$$R=\frac{N_{\mathrm{TP}}}{N_{\mathrm{TP}}+N_{\mathrm{FN}}} \tag{28}$$

$$F_1=\frac{2PR}{P+R} \tag{29}$$

式中，A为准确率；P为精确率；R为召回率；F_1为F1分数；N_{TP}为实际发生滑动且模型正确预测为滑动的样本数；N_{TN}为实际未发生滑动且模型正确预测为非滑动的样本数；N_{FP}为实际未发生滑动但模型误报为滑动的样本数；N_{FN}为实际发生滑动但模型漏报为非滑动的样本数。

3.1.3 网络训练与参数设置

在训练阶段，采用交叉熵损失函数来量化模型输出的类别概率分布与真实物理标签之间的误差，损失函数L可表示为

$$L=-\frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C}y_{i,c}\log(p_{i,c}) \tag{30}$$

式中，N为样本总数，C为类别总数(本文中C=2)；$y_{i,c}$为真实物理标签的指示变量；$p_{i,c}$为网络预测该样本属于类别c的归一化概率。

所有模型的训练均在搭载NVIDIA RTX 1080Ti GPU的Ubuntu 20.04平台上进行，训练总轮数设为100，Batch size设置为2。优化器选用Adam，初始学习率为0.001，并采用余弦退火学习率调度策略动态调整学习率，以加速模型收敛，避免陷入局部最优。

3.2 输入序列长度

在视触觉融合的滑动检测任务中，模型输入的多模态序列长度直接决定了网络所能捕获的时序动态信息的丰富程度。理论上，增加输入序列的长度能够为模型提供更丰富的时序特征，但这并不意味着检测性能会随之线性提升。当序列过长时，额外引入的数据往往包含大量与当前滑动临界状态无关的静态冗余信息，反而会干扰网络的特征提取，影响最终的检测准确率。为此，设定输入序列长度为9~15，并在GelSight数据集和Huang数据集展开了对比实验，实验结果如表1所示。当输入序列长度达到13帧时，模型的综合感知性能达到峰值，在后续的实验中选取输入序列长度为13。

表 1　不同输入序列长度下的检测效果

Table 1　Detection performance under different input sequence lengths　%

输入序列长度	GelSight				Huang			
	Accuracy	Precision	Recall	F1-Score	Accuracy	Precision	Recall	F1-Score
9	91.54	92.69	90.49	91.58	96.2	97.19	95.18	96.17
10	92.31	93.57	91.82	92.69	96.57	97.93	95.37	96.63
11	93.85	94.96	92.77	93.85	96.98	97.84	95.86	96.84
12	94.62	95.73	93.34	94.52	98.96	99.02	97.81	98.41
13	95.38	97.86	94.29	96.04	99.23	99.56	98.15	98.85
14	94.71	95.81	93.31	94.54	98.74	99.13	97.67	98.39
15	94.13	95.46	93.18	94.31	97.42	98.71	96.29	97.48

3.3　对比实验与分析

为验证所提网络的有效性与泛化能力，实验在相同的软硬件环境与超参数设置下，将本文方法与现有的VTF-AVIT[36]、视觉−触觉脉冲神经网络[16](Visual-Tactile Spiking Neural Network，VT-SNN)、ConViTac[37]、多模态视觉−触觉表征学习方法[38](Multi-modal Visual-Tactile，MViTac)及其他相关方法在GelSight数据集与Huang数据集上的表现进行了对比，实验结果如表2所示。可以看出，本文提出的视触觉融合滑动检测网络在GelSight与Huang两个数据集上均取得了最优的综合检测性能。在GelSight数据集上，Accuracy指标相比于其他方法，提升了3.84~16.10个百分点，Precision指标提升了5.85~15.29个百分点，Recall指标提升了3.43~15.46个百分点，F1-Score指标提升了4.61~15.38个百分点；在Huang数据集上，Accuracy指标相比于其他方法，提升了0.25~8.40个百分点，Precision指标提升了0.54~7.05个百分点，Recall指标提升了0.91~9.43个百分点，F1-Score指标提升了0.73~8.27个百分点。综合两组实验可以得出，本文方法能够适应不同传感器配置的滑动检测任务，同时，与现有的方法相比，本文方法在不同数据集上均保持较高的检测准确率和较低的误报、漏报风险，表明所提出网络具有较好的检测精度、鲁棒性和跨数据集适应能力，为后续真实机械臂抓取实验提供了有效支撑。

表 2　不同方法的滑动检测效果对比

Table 2　Comparison of slip detection performance among different methods　%

方法	GelSight				Huang			
	Accuracy	Precision	Recall	F1-Score	Accuracy	Precision	Recall	F1-Score
CNN-TCN[11]	84.62	85.95	83.27	84.59	94.79	96.14	93.61	94.86
CNN-LSTM[10]	82.34	84.76	81.43	83.06	93.69	94.89	92.02	93.43
TimeSFormer[28]	91.54	92.01	90.86	91.43	93.75	95.73	92.48	94.08
MS-TCN[12]	79.28	82.57	78.83	80.66	98.98	99.02	97.24	98.12
VTF-AVIT[36]	88.46	90.21	86.78	88.46	93.13	94.67	92.31	93.48
VT-SNN[16]	81.83	83.62	80.17	81.86	90.83	92.51	88.72	90.58
ConViTac[37]	87.71	89.84	85.91	87.83	91.87	93.64	90.07	91.82
MViTac[38]	86.97	88.82	85.18	86.96	91.34	93.08	89.76	91.39
本文方法	95.38	97.86	94.29	96.04	99.23	99.56	98.15	98.85

3.4　消融实验

为验证本文提出的双时滑动感知融合模块(BFM)和全局分组坐标注意力模块(GGCA)在视触觉融合滑动检测任务中的实际贡献与有效性，在GelSight数据集和Huang数据集上进行消融实验，实验结果如表3所示。可以看出，未引入任何创新模块的基础双分支网络各项指标表现均处于较低水平，这表明单纯依靠常规的特征提取网络，难以有效应对接触面微小形变和动态滑移过程中的复杂多模态特征纠缠，容易降低滑动检测的准确率。

当在基础双分支网络中单独引入双时滑动感知融合模块(BFM)时，与基础网络相比，模型在GelSight数据集上的准确率(Accuracy)、精确率(Precision)、召回率(Recall)以及F1分数(F1-Score)分别提升了3.85、4.21、3.67和3.94个百分点，在Huang数据集上分别提升了6.25、5.19、5.87和5.54个百分点。上

表 3 消融实验结果

Table 3 Ablation study results %

BFM模块	GGCA模块	GelSight				Huang			
		Accuracy	Precision	Recall	F1-Score	Accuracy	Precision	Recall	F1-Score
		89.23	90.52	88.47	89.48	92.71	93.92	91.47	92.68
√		93.08	94.73	92.14	93.42	98.96	99.11	97.34	98.22
	√	90.77	91.82	89.61	90.70	94.79	95.86	93.63	94.73
√	√	95.38	97.86	94.29	96.04	99.23	99.56	98.15	98.85

述结果表明，BFM模块通过对相邻帧下的显式特征求差建模，能够对滑动发生的瞬间触觉纹理变化与视觉宏观位移保持极高的敏感度，放大相邻帧之间特征的差异，从而提升滑动检测的准确率，同时降低滑动检测的误报率和漏报率。

当在基础双分支网络中单独引入全局分组坐标注意力模块(GGCA)时，在两个数据集上的表现与基础网络相比，四个指标均有小幅度的提升，F1分数分别提升了1.22和2.05个百分点，其余三个指标也均有1.14~2.16个百分点的涨幅。这证明GGCA模块通过对特征的空间与通道筛选，有效抑制了无效背景特征的激活权重，使得模型预测更加保守和精准，有效抑制了将稳态误判为滑动的误报现象。

最终，当BFM与GGCA模块同时作用于网络时，模型性能达到了最优状态，四个指标与基础网络相比在两个数据集上分别提升了6.15、7.34、5.82、6.56、6.52、5.64、6.68、6.17个百分点(见表3)。这一结果验证了模块设计的初衷，BFM负责捕捉动态变化，而GGCA负责去除冗余噪声，两者在特征提取链路上形成了良好的互补与协同，使得网络在最大化捕捉真实滑动事件的同时，将误触发率降至最低。

为进一步分析BFM与GGCA模块对模型复杂度和实时性的影响，本文验证了不同模块组合及对应参数量下的单个样本平均推理时间。如表4所示，未引入BFM和GGCA的基准模型参数量为13.38 M，单样本平均推理时间为36.58 ms。单独引入BFM后，模型参数量增加至18.26 M，推理时间增加至 47.43 ms；单独引入GGCA后，模型参数量增加至17.01 M，推理时间增加至43.84 ms。表明BFM 对模型复杂度和推理时间的影响更为明显，这主要是由于其需要对相邻双时刻特征进行多尺度卷积提取和时序融合。最终，同时引入BFM与GGCA 后，完整模型的参数量为21.89 M，单样本平均推理时间为50.73 ms。虽然所提出模块带来了一定的额外开销，但结合表3的实验结果可知，完整模型在两个数据集上均表现出更优的性能，在检测精度与推理速度之间取得了较好的平衡。

表 4 模型参数量与推理速度对比

Table 4 Comparison of model parameter count and inference speed

BFM模块	GGCA模块	Params/M	Latency/ms
		13.38	36.58
√		18.26	47.43
	√	17.01	43.84
√	√	21.89	50.73

3.5 数据输入模态

视觉数据与触觉数据具有不同的特点，两者差异较大但又高度互补，视觉数据能够直观地提供目标物体的几何形状、整体位移以及机械臂夹爪与物体间的空间相对关系；而触觉数据能够深入接触面内部，捕捉局部的剪切力分布和纹理位移。为了验证视触融合策略的科学性和有效性，在GelSight数据集和Huang数据集上进行了单一模态与多模态的对比实验，实验结果如表5和表6所示。可以看出，当网络仅依赖单模态时，模型的各项指标均较低，这是因为在真实的抓取过程中，视觉模态会受光线变化和机械结构遮挡的影响，触觉模态仅能感知局部接触面的受力变化，易引发误判。相比之下，视触融合策略打破了单一模态在滑动检测任务上的局限性，可以将视觉和触觉数据进行有效融合，提升滑动检测的效果。

表 5 基于GelSight数据集的滑动检测结果

Table 5 Slip detection results on the GelSight dataset %

输入模态	Accuracy	Precision	Recall	F1-Score
仅视觉	93.78	94.79	92.43	93.60
仅触觉	91.34	92.61	90.17	91.37
视触融合	95.38	97.86	94.29	96.04

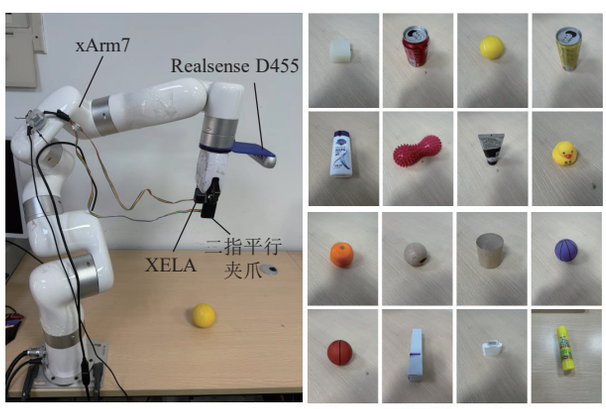
表 6 基于Huang数据集的滑动检测结果

Table 6 Slip detection results on the Huang dataset %

输入模态	Accuracy	Precision	Recall	F1-Score
仅视觉	96.69	97.73	95.26	96.48
仅触觉	95.83	96.95	94.67	95.80
视触融合	99.23	99.56	98.15	98.85

3.6　实物抓取实验验证

为了进一步验证本文提出的视触觉融合滑动检测网络的滑动检测性能，在实际环境中搭建了由xArm七自由度机械臂、RealSense D455深度相机和XELA触觉传感器组成的真实机器人抓取实验平台。如图6(a) 所示，视觉感知模块采用安装于机械臂靠近末端位置的RealSense D455深度相机，触觉感知模块则采用贴在二指平行夹爪两边的XELA触觉传感器。该平台实现了被测物体的抓取和滑动检测功能，可验证滑动检测网络在真实物理环境中的适用性。



(a) 机器人抓取实验平台　　(b) 实验测试对象

图 6　滑动检测实验设置

Fig.6　Experimental setup for slip detection

在测试对象的选取上，为了检验网络对新物体的零样本泛化能力，实验选取16个均未在数据集中出现过、不同形状、重量及表面摩擦特性的物体作为测试对象，如图6(b) 所示。在具体的验证流程中，机械臂对每一个物体均执行20次抓取、抬升，随后运动到固定位置，总共进行了320次抓取，滑动检测的准确率为98.43%，表明网络在面对真实物理环境中复杂的光照变化与夹爪机械振动干扰时，依然表现出了优异的性能。

4　结论

本文针对机器人抓取滑动检测任务中存在的滑动检测准确率和模型的泛化能力不足的问题，提出一种基于双时序动态捕捉与分组坐标注意力的视触觉滑动检测方法。该方法构建了视觉与触觉双分支的特征提取网络架构，设计了双时滑动感知融合模块和全局分组坐标注意力模块，并对跨模态的特征进行了自适应融合。在多模态数据集上的实验结果表明，本文方法的准确率、精确率、召回率、F1分数以及泛化能力均优于现有的滑动检测网络模型。同时，在真实机器人实验平台上的实验结果也证明了本文方法对于数据集未出现的物体也能达到较高的准确率，具有真实可行性和应用价值。

尽管本文所提方法在多项实验中表现良好，但在实物测试的准确率较Huang数据集低0.8个百分点。主要原因在于，Huang数据集的采集环境和抓取流程与真实机械臂抓取场景存在一定的差异和不确定性，同时还会受到夹爪震动、接触位置偏移和物体姿态变化等影响，因此滑动检测难度更高。二者均采用检测准确率作为评价指标，具有一定可比性，但由于测试环境和物体分布存在差异，该对比更侧重于验证模型从数据集场景向真实抓取场景迁移时的泛化能力。在未来的工作中，将进一步探索对形变、复杂材质和摩擦特性差异较大的物体样本进行补充扩展，以增强模型对复杂接触状态和多样化抓取场景的适应能力。同时，针对真实机械臂抓取过程中对滑动检测实时性的要求，将进一步从网络结构轻量化和推理效率优化两方面开展研究，用于提升模型在真实环境中的稳定性和应用价值。

参考文献：

[1] CALANDRA R, OWENS A, JAYARAMAN D, *et al*. More than a feeling: learning to grasp and regrasp using vision and touch[J]. IEEE Robotics and Automation Letters, 2018, 3(4): 3300-3307.

[2] ROMANO J M, HSIAO K, NIEMEYER G, *et al*. Human-inspired robotic grasp control with tactile sensing[J]. IEEE Transactions on Robotics, 2011, 27(6): 1067-1079.

[3] ROMEO R A, ZOLLO L. Methods and sensors for slip detection in robotics: a survey[J]. IEEE Access, 2020, 8: 73027-73050.

[4] VEIGA F, PETERS J, HERMANS T. Grip stabilization of novel objects using slip prediction[J]. IEEE Transactions on Haptics, 2018, 11(4): 531-542.

[5] MARX L, PÁLSDÓTTIR á A, ANDREASEN STRUIJK L N S. Frame-based slip detection for an underactuated robotic gripper for assistance of users with disabilities[J]. Applied Sciences, 2023, 13(15): 8620.

[6] MAO Q, LIAO Z, YUAN J, *et al*. Multimodal tactile sensing fused with vision for dexterous robotic housekeeping[J]. Nature Communications, 2024, 15(1): 6871.

[7] CUI S, WANG R, WEI J, *et al*. Grasp state assessment of deformable objects using visual-tactile fusion perception [C]//2020 IEEE International Conference on Robotics and Automation (ICRA) . Paris: IEEE, 2020: 538-544.

[8] JAMES J W, PESTELL N, LEPORA N F. Slip detection with a biomimetic tactile sensor[J]. IEEE Robotics and Automation Letters, 2018, 3(4): 3340-3346.

[9] HU X, VENKATESH A, WAN Y, *et al*. Learning to detect

slip through tactile estimation of the contact force field and its entropy properties[J]. Mechatronics, 2024, 104: 103258.

[10] LI J, DONG S, ADELSON E. Slip detection with combined tactile and visual information[C]//2018 IEEE International Conference on Robotics and Automation (ICRA) . Brisbane: IEEE, 2018: 7772-7777.

[11] YAN G, SCHMITZ A, TOMO T P, *et al*. Detection of slip from vision and touch[C]//2022 International Conference on Robotics and Automation (ICRA) . Philadelphia: IEEE, 2022: 3537-3543.

[12] 黄兆基, 高军礼, 唐兆年, 等. 基于注意力机制和视触融合的机器人抓取滑动检测[J]. 信息与控制, 2024, 53(2): 191-198.
HUANG Z J, GAO J L, TANG Z N, *et al*. Slip detection for robot grasping based on attention mechanism and visuo-tactile fusion[J]. Information and Control, 2024, 53(2): 191-198.

[13] LEE M A, ZHU Y, SRINIVASAN K, *et al*. Making sense of vision and touch: self-supervised learning of multimodal representations for contact-rich tasks[C]//2019 International Conference on Robotics and Automation (ICRA) . Montreal: IEEE, 2019: 8943-8950.

[14] LIANG W, FANG F, ACAR C, *et al*. Visuo-tactile feedback-based robot manipulation for object packing[J]. IEEE Robotics and Automation Letters, 2023, 8(2): 1151-1158.

[15] DING Z, CHEN G, WANG Z, *et al*. Adaptive visual–tactile fusion recognition for robotic operation of multi-material system[J]. Frontiers in Neurorobotics, 2023, 17: 1181383.

[16] TAUNYAZOV T, SNG W, SEE H H, *et al*. Event-driven visual-tactile sensing and learning for robots[EB/OL]. arXiv: 2009.07083(2020-09-15) [2026-03-20]. https://arxiv.org/abs/2009.07083.

[17] MUTHUSAMY R, HUANG X, ZWEIRI Y, *et al*. Neuromorphic event-based slip detection and suppression in robotic grasping and manipulation[J]. IEEE Access, 2020, 8: 153364-153384.

[18] ZHOU Z, ZUO R, DU M, *et al*. A cable-driven soft robotic hand with an in-hand rgb-d camera for dexterous grasping and manipulation[J]. IEEE Transactions on Robotics, 2025, 42: 600-618.

[19] KOMENO N, MATSUBARA T. Incipient slip detection by vibration injection into soft sensor[J]. IEEE Robotics and Automation Letters, 2024, 9(4): 3251-3258.

[20] GRIFFA P, SFERRAZZA C, D'ANDREA R. Leveraging distributed contact force measurements for slip detection: a physics-based approach enabled by a data-driven tactile sensor[C]//2022 International Conference on Robotics and Automation (ICRA) . Philadelphia: IEEE, 2022: 4826-4832.

[21] WANG Q, ULLOA P M, BURKE R, *et al*. Robust learning-based incipient slip detection using the papillarray optical tactile sensor for improved robotic gripping[J]. IEEE Robotics and Automation Letters, 2023, 9(2): 1827-1834.

[22] ZHANG Z, SUN H, ZHOU Z, *et al*. Learning to regrasp using visual–tactile representation-based reinforcement learning[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-11.

[23] TANG Q, CHEN L, LIU J, *et al*. VTMF^{2}N: towards accurate visual-tactile slip detection via multi-modal feature fusion in robotic grasping[C]//Chinese Conference on Pattern Recognition and Computer Vision (PRCV) . Singapore: Springer Nature Singapore, 2024: 103-117.

[24] RUAN W, ZHU W, ZHAO Z, *et al*. RFCT: multimodal sensing enhances grasping state detection for weak-stiffness targets[J]. Mathematics, 2023, 11(18): 3969.

[25] YANG Z, ZHU W, ZHAO Z, *et al*. YGC: visual–tactile stabilized grasping for targets with weak-stiffness characteristics[J]. Intelligent Service Robotics, 2026, 19(2): 43.

[26] VASWANI A, SHAZEER N, PARMAR N, *et al*. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS). Long Beach: Curran Associates Inc, 2017: 5998-6008.

[27] BERTASIUS G, WANG H, TORRESANI L. Is space-time attention all you need for video understanding?[C]//Proceedings of the 38th International Conference on Machine Learning (ICML). Virtual Event:PMLR, 2021: 813-824.

[28] HAN Y, YU K, BATRA R, *et al*. Learning generalizable vision-tactile robotic grasping strategy for deformable objects via transformer[J]. IEEE/ASME Transactions on Mechatronics, 2024, 30(1): 554-566.

[29] LIU Z, NING J, CAO Y, *et al*. Video swin transformer [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR) . New Orleans: IEEE, 2022: 3202-3211.

[30] WANG L, TONG Z, JI B, *et al*. Tdn: temporal difference networks for efficient action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR) . Virtual Event: IEEE, 2021: 1895-1904.

[31] 邓立国, 沙文丹. SCA-YOLO: 基于可变形卷积与上下文感知注意力的实时目标检测[J]. 广东工业大学学报, 2026, 43(2): 12-20.
DENG L G, SHA W D. SCA-YOLO: real-time target detection based on deformable convolution and context-aware attention[J]. Journal of Guangdong University of Technology, 2026, 43(2): 12-20.

[32] HU J, SHEN L, SUN G. Squeeze-and-excitation networks [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition(CVPR) . Salt Lake City: IEEE, 2018: 7132-7141.

[33] WOO S, PARK J, LEE J Y, *et al*. Cbam: convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV) . Munich: Spring-

er, 2018: 3-19.

[34] FU J, LIU J, TIAN H, *et al*. Dual attention network for scene segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern recognition(CVPR) . Long Beach: IEEE, 2019: 3146-3154.

[35] HOU Q, ZHOU D, FENG J. Coordinate attention for efficient mobile network design[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR) . Virtual Event: IEEE, 2021: 13713-13722.

[36] LIU C W, WU H, SHEN J J. Efficient visual-tactile transformer with token reorganization for robotic slip detection [J]. Journal of the Brazilian Society of Mechanical Sciences and Engineering, 2025, 47(6): 265.

[37] WU Z, ZHAO Y, LUO S. Convitac: aligning visual-tactile fusion with contrastive representations[C]//2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS) . Hangzhou: IEEE, 2025: 8545-8552.

[38] DAVE V, LYGERAKIS F, RUECKERT E. Multimodal visual-tactile representation learning through self-supervised contrastive pre-training[C]//2024 IEEE International Conference on Robotics and Automation (ICRA) . Yokohama: IEEE, 2024: 8013-8020.

（责任编辑：王威娜　英文审核：费伦科）